

CASE STUDY: PHÂN TÍCH GIỎ HÀNG

ThS. Lê Thị Thùy Trang

2025-11-25

1 Bán lẻ dựa trên dữ liệu (Data-Driven Retail)

1.1 Giới thiệu dự án

Trong bối cảnh nền kinh tế số hiện đại, việc áp dụng một chiến lược bán hàng duy nhất cho toàn bộ thị trường không còn mang lại hiệu quả tối ưu. Khách hàng ngày nay mong đợi sự cá nhân hoá trong trải nghiệm mua sắm và dịch vụ. Đây là lúc bài toán Market Basket Analysis (Phân tích giỏ hàng) trở nên cấp thiết. Phân tích giỏ hàng là quá trình khám phá các mẫu kết hợp giữa các sản phẩm trong giao dịch của khách hàng, dựa trên những đặc điểm tương đồng như hành vi mua sắm hoặc tần suất xuất hiện chung. Mục tiêu cốt lõi của việc này bao gồm:

- Tối ưu hoá chiến lược Marketing: thay vì khuyến mãi chung chung, doanh nghiệp có thể đề xuất ”đồ mẹ và bé” kèm theo khi khách hàng mua sản phẩm liên quan, hoặc ”thiết bị công nghệ” cho nhóm khách hàng trẻ yêu thích kỹ thuật số.
- Tăng doanh thu: Nhận diện các sản phẩm thường mua cùng nhau để tạo gói combo, giảm nguy cơ bỏ lỡ cơ hội bán hàng.
- Phân bổ nguồn lực: Tập trung ngân sách vào các sản phẩm mang lại giá trị lợi nhuận cao nhất dựa trên các quy tắc kết hợp mạnh.

Để thực hiện việc phân tích này một cách tự động và chính xác trên tập dữ liệu lớn, chúng ta không thể thực hiện thủ công mà cần sự hỗ trợ của các thuật toán khai phá dữ liệu. Ta sử dụng Apriori để giải quyết bài toán luật kết hợp trên dữ liệu giao dịch chưa được gán nhãn.

Trong dự án này, chúng ta sẽ đóng vai trò là một Data Scientist cho một chuỗi bán lẻ với nhiệm vụ phân tích dữ liệu giao dịch và xây dựng mô hình luật kết hợp để khám phá mẫu mua sắm. Dự án này được thiết kế dành cho các kỹ sư dữ liệu và nhà khoa học dữ liệu tương lai. Dự án tuân thủ triết lý lập trình hướng đối tượng thay vì tiếp cận vấn đề theo notebook rời rạc. Các bước thực hiện bao gồm:

1. Khám phá dữ liệu: Hiểu cấu trúc và phân bố của tập dữ liệu.
2. Thu thập và làm sạch dữ liệu giao dịch thô.
3. Chuyển đổi dữ liệu về dạng phù hợp cho thuật toán khai phá luật (danh sách các sản phẩm trong từng giỏ hàng).
4. Áp dụng Apriori: Tìm các tập phổ biến và luật với các ngưỡng tối ưu.
5. Phân tích kết quả: Trực quan hoá các rules và đưa ra đề xuất kinh doanh.




Figure 1: Pipeline project

1.2 Danh sách các module trong project

Để đảm bảo tính chuyên nghiệp, dự án này áp dụng tư duy lập trình hướng đối tượng (OOP). Thay vì viết hàng trăm dòng script xử lý rồi rả vào chính những file notebook mà chúng ta trình bày, chúng ta đóng gói logic vào các lớp (Class) trong một file riêng. Sau đó, khi làm việc với notebook ta có, ta sẽ sử dụng hàm import để sử dụng các lớp nói trên. Điều này giúp notebook sạch sẽ, tập trung vào kết quả và dễ dàng tái sử dụng.

Ví dụ minh họa sự tinh gọn:

```

from apriori_library import DataCleaner, DataVisualizer
# Code ngắn gọn, dễ hiểu
visualizer = DataVisualizer()
  
```

Thành phần	Ý nghĩa và chức năng
src/apriori_library.py	Thư viện trung tâm của dự án, chứa các lớp (class) xử lý chính: DataCleaner (làm sạch dữ liệu), BasketPreparer (tạo danh sách giỏ hàng), AssociationRulesMiner (thực hiện thuật toán Apriori, sinh luật kết hợp) và DataVisualizer (trực quan hoá).
notebooks/preprocessing_and_eda.ipynb	Notebook bước 1: Thực hiện tải dữ liệu thô, xử lý các giá trị thiếu, lọc dữ liệu rác (đơn hàng bị hủy) và thực hiện phân tích khám phá dữ liệu (EDA) để hiểu tổng quan về tập dữ liệu.
notebooks/basket_preparation.ipynb	Notebook chuẩn bị dữ liệu giỏ hàng (basket) từ dữ liệu giao dịch gốc: lọc các đơn hàng hợp lệ, nhóm các sản phẩm theo từng đơn hàng và lưu ra định dạng phù hợp cho bước áp dụng thuật toán Apriori.
notebooks/apriori_modelling.ipynb	Notebook bước 3: Notebook này sử dụng ma trận basket_bool (được chuẩn bị ở bước 2) để khai thác tập mục phổ biến bằng thuật toán Apriori; sinh luật kết hợp với các chỉ số support, confidence, lift.
run_papermill.py	Script điều phối toàn bộ pipeline: sử dụng thư viện papermill để tự động chạy lần lượt các notebook preprocessing_and_eda.ipynb, basket_preparation.ipynb, apriori_modelling.ipynb với các tham số cấu hình; lưu lại các notebook sau khi thực thi, ghi nhận thời gian chạy (execution time) và giúp bạn có thể tái chạy toàn bộ quy trình chỉ bằng một lệnh từ dòng lệnh.
data/	Thư mục chứa dữ liệu đầu vào (online_retail.csv) và lưu trữ các dữ liệu trung gian đã qua xử lý (processed data) để sử dụng giữa các bước phân tích.

Table 1: Bảng thành phần Project

1.3 Giới thiệu Papermill: Tự động hoá pipeline Notebook

Trong dự án này, chúng ta sử dụng thư viện `papermill` để điều phối việc thực thi tuần tự các bước: tiền xử lý (*preprocessing*), chuẩn bị giỏ hàng (*basket preparation*) và mô hình hoá luật kết hợp (*Apriori modelling*).

Thay vì mở từng notebook và chạy thủ công nhiều lần, `papermill` cho phép:

- Tự động chạy toàn bộ pipeline chỉ bằng một lệnh.
- Ghi lại kết quả vào các notebook đã thực thi.
- Thay đổi tham số đầu vào mà không chỉnh lại mã nguồn.
- Đảm bảo tính lặp lại (*reproducibility*) trong phân tích.

Cách làm này phản ánh tư duy của các hệ thống phân tích dữ liệu chuyên nghiệp:

- Notebook không chỉ để trình bày mà còn là thành phần của pipeline.
- Tách biệt *logic phân tích* (nằm trong thư viện) khỏi *quy trình thực thi*.
- Giảm thiểu *rủi ro thao tác thủ công* và nhầm lẫn khi tái chạy.

Sinh viên không cần hiểu sâu về cơ chế nội bộ của `papermill`, nhưng cần nắm ý nghĩa của việc tự động hoá pipeline: đây là một bước tiến từ tư duy phân tích *mang tính trình diễn* sang tư duy *kỹ sư dữ liệu*, nơi các quy trình được chuẩn hoá, tái lập và dễ chuyển giao.

1.4 Chuẩn bị môi trường thực hành

Kích hoạt môi trường ảo

```
conda activate shopping_env
```

Toàn bộ các thư viện cần thiết cho dự án được liệt kê trong file `requirements.txt`. Vì vậy, sau khi kích hoạt môi trường, cài đặt các thư viện cần thiết bằng câu lệnh:

```
pip install requirements.txt
```

2 Nhắc lại kiến thức: Khai phá luật kết hợp

Khai phá luật kết hợp không chỉ đơn thuần là tìm kiếm các mẫu xuất hiện cùng nhau, mà là việc xác định các mối quan hệ có ý nghĩa thống kê và giá trị kinh tế. Một luật kết hợp thường được biểu diễn dưới dạng $X \rightarrow Y$, trong đó X là vế trái (tiền đề) và Y là vế phải (hệ quả). Để lọc bỏ hàng triệu tổ hợp ngẫu nhiên và giữ lại những quy tắc cốt lõi, chúng ta sử dụng hệ thống các chỉ số đo lường chính.

2.1 Độ hỗ trợ (Support)

Support đo lường tần suất xuất hiện của một tập sản phẩm trong toàn bộ cơ sở dữ liệu giao dịch. Đối với một quy tắc $X \rightarrow Y$, Support được tính bằng tỷ lệ phần trăm các giao dịch chứa cả X và Y trên tổng số giao dịch N . Công thức toán học được định nghĩa như sau:

$$\text{Support}(X \rightarrow Y) = P(X \cup Y) = \frac{\text{Số giao dịch chứa } X \text{ và } Y}{N}$$

Đối với dữ liệu bán lẻ trực tuyến với hàng nghìn mã sản phẩm, hầu hết các sản phẩm chỉ xuất hiện trong một phần rất nhỏ các giỏ hàng. Việc thiết lập ngưỡng `min_support` là bước lọc đầu tiên và quan trọng nhất. Nếu ngưỡng này

quá cao, chúng ta sẽ bỏ lỡ các quy tắc “Long-tail” (đuôi dài) - những sản phẩm ngách nhưng có lợi nhuận cao. Ngược lại, nếu ngưỡng quá thấp, thuật toán sẽ bị quá tải bởi các kết hợp nhiều và chi phí tính toán sẽ bùng nổ, đặc biệt với thuật toán Apriori

2.2 Độ tin cậy (Confidence)

Confidence trả lời câu hỏi: “Nếu một khách hàng đã mua nhóm sản phẩm X , thì khả năng bao nhiêu phần trăm họ sẽ mua tiếp sản phẩm Y ?”. Đây thực chất là xác suất có điều kiện $P(Y|X)$.²

$$\text{Confidence}(X \rightarrow Y) = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)}$$

Chỉ số Confidence thể hiện “độ mạnh” của mối quan hệ theo một chiều. Tuy nhiên, một cạm bẫy lớn khi chỉ sử dụng Confidence là nó bỏ qua độ phổ biến tự nhiên của Y . Ví dụ, nếu Y là một sản phẩm cực kỳ phổ biến (như túi nilon hoặc phí vận chuyển), thì Confidence của bất kỳ sản phẩm X nào dẫn tới Y đều sẽ cao, nhưng mối quan hệ đó không mang lại giá trị dự báo thực sự. Do đó, Confidence cần luôn được đánh giá song song với Lift.

2.3 Độ nâng (Lift)

Lift là chỉ số quan trọng nhất để đánh giá xem mối quan hệ giữa X và Y có thực sự tồn tại hay chỉ là ngẫu nhiên. Nó so sánh Confidence quan sát được với Confidence mong đợi nếu X và Y độc lập thống kê.²

$$\text{Lift}(X \rightarrow Y) = \frac{\text{Confidence}(X \rightarrow Y)}{\text{Support}(Y)} = \frac{\text{Support}(X \cup Y)}{\text{Support}(X) \times \text{Support}(Y)}$$

Ý nghĩa của Lift trong ra quyết định kinh doanh được phân loại rõ ràng:

- Lift > 1: X và Y có tương quan dương. Sự xuất hiện của X làm tăng khả năng xuất hiện của Y . Đây là các cặp sản phẩm bổ trợ (Complements), là mục tiêu vàng cho chiến lược Bán chéo (Cross-selling).
- Lift = 1: X và Y độc lập. Không có mối liên hệ nào.
- Lift < 1: X và Y có tương quan âm. Sự xuất hiện của X làm giảm khả năng mua Y . Đây thường là các sản phẩm thay thế - ví dụ, khách hàng mua bột giặt nhãn hiệu A thường sẽ không mua bột giặt nhãn hiệu B trong cùng một lần.

2.4 Ví dụ minh họa một luật kết hợp

Giả sử trong quá trình khai phá, ta thu được luật sau:

$$\{\text{WHITE HANGING HEART}\} \Rightarrow \{\text{RED WOOLLY HOTTIE}\}$$

với các chỉ số:

$$\text{Support} = 0.03, \quad \text{Confidence} = 0.45, \quad \text{Lift} = 2.1$$

Diễn giải theo ngôn ngữ kinh doanh:

- Support = 3%: Có 3% tổng số hoá đơn chứa cả hai sản phẩm, nghĩa là cặp sản phẩm này có sự xuất hiện thực tế trong dữ liệu.
- Confidence = 45%: Nếu một khách đã mua WHITE HANGING HEART thì có 45% khả năng họ sẽ mua thêm RED WOOLLY HOTTIE.
- Lift = 2.1: Xác suất mua HOTTIE khi đã mua HEART cao gấp 2.1 lần so với tổng thể, cho thấy đây là quan hệ bổ trợ (complementary).

Một số đề xuất kinh doanh đơn giản:

- Sắp xếp hai sản phẩm này gần nhau trên kệ hoặc giao diện web.
- Tạo chương trình combo hoặc gợi ý mua kèm.
- Hiện thị gợi ý “Khách mua HEART thường mua kèm HOTTIE”.

3 Phân tích và làm sạch dữ liệu

3.1 Tổng quan về tập dữ liệu

Tập dữ liệu Online Retail Data được trích từ UCI Machine Learning Repository, chứa các giao dịch mua bán của một doanh nghiệp bán lẻ trực tuyến tại Anh chuyên cung cấp quà tặng và đồ gia dụng. Dữ liệu bao quát giai đoạn từ 01/12/2010 đến 09/12/2011, với khách hàng đến chủ yếu từ Vương quốc Anh, nhưng cũng có giao dịch từ châu Âu và các khu vực khác. Mỗi bản ghi chứa thông tin chi tiết về mã hóa đơn, mã sản phẩm, tên sản phẩm, số lượng bán, thời điểm giao dịch, đơn giá, mã khách hàng và quốc gia.

Tổng cộng dataset gồm 541.909 giao dịch, với khoảng 4.400 khách hàng và gần 4.000 loại sản phẩm, trải rộng trên 37 quốc gia, với cấu trúc được trình bày ở bảng 2:

Column	Type	Description	Example
InvoiceNo	object	Mã hóa đơn (6 chữ số, 'C' = canceled)	536365
StockCode	object	Mã sản phẩm (5 chữ số)	85123A
Description	object	Tên sản phẩm	WHITE HANGING HEART
Quantity	int64	Số lượng sản phẩm	6
InvoiceDate	datetime	Thời gian giao dịch	2010-12-01 08:26:00
UnitPrice	float64	Đơn giá (GBP)	2.55
CustomerID	object	ID khách hàng (5-6 chữ số)	17850
Country	object	Quốc gia khách hàng	United Kingdom

Table 2: Cấu trúc dữ liệu raw

Tập dữ liệu này mang lại nhiều cơ hội phân tích nhờ tính chi tiết và giàu thông tin, đặc biệt trong khai phá luật kết hợp để hiểu hành vi mua sắm. Tuy nhiên, dữ liệu cũng tồn tại những thách thức như thiếu CustomerID (~25% bản ghi), dữ liệu hủy trả hàng (Quantity âm), phân phối lệch và một số giao dịch có giá trị bất thường. Mặc dù vậy, nhờ tính chất phong phú về thời gian, sản phẩm và chi tiết khách hàng, tập dữ liệu này rất phù hợp để khám phá xu hướng chi tiêu, nhóm sản phẩm phổ biến và insight phục vụ khai phá tri thức thương mại.

3.2 Làm sạch dữ liệu

Các bước tiền xử lý được thực hiện để làm sạch dữ liệu:

1. Tính tổng giá trị mỗi dòng: Tạo cột mới $TotalPrice = Quantity \times UnitPrice$ để biết doanh số của từng dòng sản phẩm trong hóa đơn.
2. Loại bỏ đơn hàng bị hủy: Xóa các giao dịch có mã hóa đơn bắt đầu bằng chữ "C" (Cancelled) vì đây là những hóa đơn trả hàng hoặc hủy bỏ.
3. Lọc theo địa lý: Giữ lại các giao dịch trong nước Anh (United Kingdom), loại bỏ các nước khác nhằm đảm bảo hành vi mua sắm đồng nhất về mặt địa lý.
4. Xử lý dữ liệu thiếu: Loại bỏ các dòng không có CustomerID (không xác định được khách hàng). Mặc dù phân tích giỏ hàng không yêu cầu ID khách hàng, các giao dịch thiếu thông tin này thường là giao dịch vắng lai có thể

không đáng tin cậy hoặc khó đối chiếu.

- Loại bỏ giá trị bất thường: Loại bỏ những mục có Quantity hoặc UnitPrice âm (ví dụ giao dịch nhập sai hoặc hủy) hoặc bằng 0 (không mang thông tin mua hàng thực).

Thực hiện lần lượt các bước trên giúp làm sạch dữ liệu và loại bỏ nhiễu, đảm bảo chất lượng cho phân tích tiếp theo. Sau đây là ví dụ mã lệnh Python áp dụng các bước làm sạch trên:

```
# Thực hiện quy trình làm sạch dữ liệu
df_clean = cleaner.clean_data() # hàm clean_data() thực hiện các bước đã liệt kê
cleaner.create_time_features() # tạo thêm cột thời gian (giờ, thứ trong tuần) nếu cần

print(f"Số lượng giao dịch sau khi làm sạch: {len(df_clean)}")
```

Sau khi làm sạch và tập trung vào dữ liệu từ thị trường UK, ta thu được 397.924 giao dịch hợp lệ của 4.373 khách hàng trong vòng 374 ngày, với giá trị giao dịch dao động từ £0.001 đến £38.970.

4 Chuyển đổi dữ liệu thành các giao dịch

Để khai thác luật kết hợp, dữ liệu cần được chuyển sang dạng các giỏ hàng, trong đó mỗi giao dịch là một danh sách các sản phẩm đã được mua cùng nhau. Ở dạng bảng hiện tại, dữ liệu đang ở cấu trúc dạng dài (mỗi dòng là một sản phẩm trong một hóa đơn). Ta cần gom lại các sản phẩm theo từng mã hóa đơn (InvoiceNo). Nói cách khác, mỗi hóa đơn sẽ trở thành một transaction chứa tập hợp các sản phẩm được mua trong hóa đơn đó.

Cụ thể, chúng ta nhóm dữ liệu theo InvoiceNo và tổng hợp danh sách Description (tên sản phẩm) cho mỗi hóa đơn. Kết quả thu được là một danh sách các giỏ hàng, ví dụ: hóa đơn #10001 có các sản phẩm [A, B, C], hóa đơn #10002 có [A, D], v.v. Lưu ý rằng ta chỉ quan tâm đến sự có mặt của sản phẩm trong giỏ (mua hay không mua), không phân biệt số lượng nhiều ít – do đó nếu một sản phẩm xuất hiện nhiều lần trong cùng hóa đơn, ta cũng chỉ tính một lần. Dưới đây là mã lệnh thực hiện việc chuyển đổi:

```
def create_basket(self):
    """
    Create a basket format dataframe for Apriori algorithm.

    Returns:
        pd.DataFrame: Basket format dataframe
    """

    basket = (
        self.df.groupby([self.invoice_col, self.item_col])[self.quantity_col]
        .sum()
        .unstack()
        .fillna(0)
    )

    self.basket = basket
    return self.basket
```

Để áp dụng thuật toán Apriori, chúng ta cần biểu diễn dữ liệu giao dịch dưới dạng ma trận phẳng (one-hot encoding): mỗi cột tương ứng với một sản phẩm (mục hàng), mỗi dòng tương ứng với một giao dịch, giá trị là 1 nếu sản phẩm có trong giao dịch đó và 0 nếu không có. Ma trận này thường rất thưa (vì mỗi giao dịch chỉ chứa một tập con nhỏ trong hàng ngàn sản phẩm có thể có).

Code mã hóa danh sách các giao dịch thành ma trận one-hot:

```
def encode_basket(self, threshold: int = 1):
    """
    Encode the basket dataframe into boolean format.

    Args:
        threshold (int): Minimum quantity to consider an item as present

    Returns:
        pd.DataFrame: Boolean encoded basket dataframe
    """

    if self.basket is None:
        raise ValueError("Basket not created. Please run create_basket() first.")
    basket_bool = self.basket.applymap(lambda x: 1 if x >= threshold else 0)
    basket_bool = basket_bool.astype(bool)
    self.basket_bool = basket_bool
    return self.basket_bool
```

Sau đó ta lưu dữ liệu đã chuẩn hoá cho bài toán áp dụng luật kết hợp vào file `basket_bool.parquet`. Ta lưu trữ trên file `.parquet` định dạng này tiết kiệm RAM hơn so với file `.csv`.

5 Khai phá luật kết hợp với thuật toán Apriori

Thuật toán Apriori sẽ giúp tìm ra các tập hợp sản phẩm phổ biến (frequent itemsets) thỏa mãn một ngưỡng độ phổ biến tối thiểu, gọi là ngưỡng support. Nói một cách đơn giản, Apriori duyệt qua các kết hợp sản phẩm có thể có và loại bỏ sớm những kết hợp không đạt tần suất xuất hiện tối thiểu. Thuật toán dựa trên thuộc tính Apriori: “Mọi tập con của một tập hợp phổ biến thì cũng phải phổ biến”. Nhờ thuộc tính này, Apriori cắt giảm không gian tìm kiếm: nếu một bộ sản phẩm nào đó xuất hiện không đủ thường xuyên, thì mọi bộ sản phẩm mở rộng từ nó (thêm sản phẩm khác vào) cũng sẽ bị loại bỏ.

Dưới đây là tham số hiện tại trong dự án:

```
FILTER_MIN_SUPPORT = 0.01
FILTER_MIN_CONF = 0.3
FILTER_MIN_LIFT = 1.2
```

Trong dự án này, ta chọn ngưỡng `support = 0.01 (1%)` – tức chỉ quan tâm những tập sản phẩm xuất hiện trong ít nhất `1%` tổng số giao dịch. (Ngưỡng này có thể điều chỉnh tùy mục tiêu phân tích: chọn cao hơn để tập trung vào các kết hợp rất phổ biến, hoặc thấp hơn để tìm các mẫu hiếm hơn nhưng thú vị). Sau khi có danh sách các tập mục phổ biến, ta tiếp tục trích xuất các luật kết hợp thỏa mãn ngưỡng độ tin cậy tối thiểu. Giả sử ta đặt `min_confidence = 0.3 (30%)`, nghĩa là chỉ giữ lại những luật mà xác suất mua sản phẩm Y khi đã mua X ít nhất là `30%`. Chúng ta sử dụng hàm `association_rules` của `mlxtend` để sinh ra luật từ tập phổ biến và tính các chỉ số cho từng luật.

5.1 Cách đọc và diễn giải các biểu đồ trực quan

Trong phần trực quan hoá, mỗi biểu đồ cung cấp một góc nhìn về cấu trúc luật. Một số cách diễn giải phổ biến:

1. Biểu đồ cột (Bar chart)
 - Thể hiện top luật hoặc top tập mục phổ biến.
 - Các cột có **support cao** thường là các kết hợp quan trọng về mặt thị trường.
 - Các cột có **lift cao** dù support thấp thường là các mẫu chuyên sâu (niche), hữu ích cho chiến lược bán chéo.
2. Biểu đồ scatter (support vs confidence)

- Mỗi điểm biểu diễn một luật.
 - Điểm nằm ở vùng **support đủ, confidence cao, lift > 1** là mục tiêu tốt.
 - Điểm có **confidence cao nhưng lift ≈ 1** thường là quan hệ giả do về phải quá phổ biến.
3. Biểu đồ network graph (đồ thị sản phẩm)
- Các nút (node) là sản phẩm; cạnh (edge) thể hiện quan hệ.
 - Cụm các nút kết nối chặt có thể biểu diễn nhóm sản phẩm nên được bố trí gần nhau.
 - Node có bậc (degree) lớn thể hiện sản phẩm trung tâm (hub).

Khi viết báo cáo, sinh viên cần mô tả “*biểu đồ kể câu chuyện gì*”, tránh chỉ đưa hình minh họa.

5.2 Các chiều phân tích insight từ luật kết hợp

Luật kết hợp có thể mang nhiều góc nhìn khác nhau. Một số chiều phân tích gợi ý:

1. **Theo sản phẩm (Product-level):** Xác định sản phẩm đóng vai trò trung tâm (xuất hiện trong nhiều luật).
2. **Theo nhóm sản phẩm (Category-level):** Xem xét các luật tập trung trong cùng một nhóm hàng (ví dụ: quà tặng, đồ trang trí).
3. **Theo thời gian (Temporal insight):** Các luật có xuất hiện theo mùa? Theo tháng?
4. **Theo hành vi khách hàng (Behavioral):** Liệu có xu hướng “mua A thì mua B” thể hiện hành vi hỗ trợ? Có dấu hiệu thay thế (substitution) khi lift < 1?

Mục tiêu cuối cùng là chuyển luật thành **hành động kinh doanh khả thi**.

6 Thực hành tại lớp

Q1: Sinh viên đọc hiểu cấu trúc dự án, sau đó thay đổi tham số để hiển thị tất cả các biểu đồ trực quan dữ liệu.

Q2: Sinh viên thay đổi tham số support, confidence, lift trong file `apriori_library.py` và nhận xét tác động của việc lựa chọn các tham số này đến kết quả

7 Hướng dẫn thực hiện hoạt động FIT-DNU CONQUER

7.1 Mục tiêu của hoạt động

Hoạt động FIT-DNU CONQUER được thiết kế nhằm giúp sinh viên:

- Hiểu sâu bản chất của khai phá luật kết hợp (Apriori) thông qua việc ứng dụng trên dữ liệu thực.
- Tập diễn giải kết quả bằng ngôn ngữ đơn giản (Feynman style), tránh chỉ mô tả code hoặc trích xuất số liệu.
- Rèn luyện khả năng trình bày, giải thích và thuyết phục thông qua hoạt động chia sẻ kết quả.
- Phát triển tư duy phân tích theo góc nhìn kinh doanh và đưa ra đề xuất hành động.

Sinh viên cần xem xét dự án như một nhiệm vụ Data Scientist thực thụ: không chỉ “chạy đúng thuật toán”, mà phải chuyển dữ liệu thành tri thức hữu ích.

7.2 Yêu cầu

Đối với mỗi nhóm (3-4 sinh viên), yêu cầu thực hiện như sau:

1. **Thiết lập và chạy pipeline Apriori:**

- Sử dụng cấu trúc thư viện OOP đã cung cấp.
- Chạy pipeline đầy đủ: làm sạch dữ liệu, chuẩn bị basket, khai thác luật.

2. Thay đổi và phân tích tham số:

- Thử nghiệm với các giá trị `min_support`, `min_confidence`, `min_lift`.
- Đưa ra nhận xét về sự thay đổi kết quả.

3. Trực quan hóa:

- Tối thiểu 02 biểu đồ (bar chart, scatter plot, network graph, ...).
- Mỗi biểu đồ cần kèm diễn giải ý nghĩa.

4. Insight:

- Tối thiểu 05 insight chất lượng.
- Insight phải trả lời câu hỏi: “Nếu là quản lý cửa hàng, tôi có thể làm gì?”

5. Báo cáo dạng blog:

- Trình bày logic, rõ ràng, súc tích.
- Không trình bày dưới dạng dump code hoặc copy bảng luật.
- Ngôn ngữ đơn giản, hướng tới người đọc không chuyên.

6. Trình bày và chia sẻ kết quả:

- Thời lượng trình bày: 5–7 phút.
- Không đọc code.
- Dùng Feynman style: giải thích như đang dạy một người khác.

7.3 Các chủ đề gợi ý phát triển từ bài mẫu

Mỗi nhóm sẽ chọn một trong các chủ đề dưới đây để triển khai và trình bày.

7.3.1 Chủ đề 1: Phân tích luật theo thời gian (Temporal Association)

- Xem xét hành vi khách hàng theo tháng/quý.
- So sánh số lượng luật và độ mạnh giữa các giai đoạn.
- Nhận định “mùa vụ” của các combo sản phẩm.

7.3.2 Chủ đề 2: Tìm sản phẩm trung tâm (Product Hub)

- Xác định sản phẩm xuất hiện nhiều nhất trong các luật.
- Đánh giá vai trò “hub” trong chiến lược cross-selling.
- Đề xuất cách bố trí hàng hóa.

7.3.3 Chủ đề 3: Đánh giá luật theo Lift và giá trị kinh doanh

- Xếp hạng luật theo Lift.
- Phân loại:
 1. Support cao, Lift cao
 2. Support thấp, Lift cao (niche)
 3. Confidence cao, Lift ≈ 1 (không giá trị thực)
- Đưa ra đề xuất marketing tương ứng.

7.3.4 Chủ đề 4: Phân tích độ nhạy tham số (Parameter Sensitivity)

- Sử dụng nhiều giá trị `min_support` khác nhau.
- Quan sát sự thay đổi về:
 1. Số lượng luật
 2. Chất lượng luật
 3. Cụm sản phẩm
- Rút ra “ngưỡng hợp lý” cho bài toán.

7.3.5 Chủ đề 5: Phân tích bằng Network Graph

- Trực quan dữ liệu luật dưới dạng đồ thị sản phẩm.
- Tìm cụm sản phẩm, đánh giá mối quan hệ chặt lỏng.
- Nhận diện nhóm sản phẩm nên trưng bày cạnh nhau.

7.3.6 Chủ đề 6: Nhóm sản phẩm (Category-level Insight)

- Gán danh mục sản phẩm (ví dụ: quà tặng, trang trí, gia dụng).
- So sánh mức độ kết hợp trong từng nhóm.
- Nhận định nhóm sản phẩm có tiềm năng marketing cao.

7.3.7 Chủ đề 7: Tập trung vào luật “niche” (Hiếm nhưng Lift cao)

- Xem xét các luật có support thấp nhưng lift cao.
- Phân tích lý do tại sao các luật này đáng chú ý.
- Đề xuất chiến lược bán hàng chuyên sâu theo phân khúc.

7.3.8 Chủ đề 8: Phân tích “luật bất ngờ” (Unexpected Patterns)

- Tìm luật trái dự đoán hoặc bất thường.
- Kiểm chứng lại bằng EDA/ngữ cảnh sản phẩm.
- Tạo thành case study thảo luận.

7.4 Kết quả kỳ vọng

Mỗi nhóm cần hoàn thành:

- Blog/Report (link Notion/GitHub).
- Slide trình bày.

7.5 Gợi ý cho phần trình bày tại lớp

1. Giới thiệu bài toán và mục tiêu nhóm.
2. Trình bày kết quả trọng tâm (không kể lể, không giải thích code).
3. Diễn giải các biểu đồ.
4. Kết luận và đề xuất hành động.